

èfjç» - ç” µè`❖i¼š188-5665-3017 - é,®ç®±i¼šhs3434@foxmail.com -
ä, º°ç½ ‘ç«™i¼šhs3434.github.io - **æ±
,è❖Ææ,,❖â❖ ‘**i¼šAMD ROCm Python â❖Žç«`â¼â❖ ‘â • ¥ç`â, ^i¼^ROCm Radeon Cloud
æ-¹â❖ ‘i¼% --- ## ä, º°ç®€ä» 3 â¹´ç” Ýç%©äçæ❖-â • ¥ç`â❖-ç»❖éâEi¼Eè ± ââ|è½-âž`
K8s â❖Žç«`æ ^â€, ä, “æ³`**â®¹â™`â❖-éf`ç½²â❖èµ,,æ°❖è`fâ|â❖ä»âŠç¼-
æŽ` â❖GPU æŽ`ç❖ + æœ❖âŠç; **â€, æœ€èç` ‘6 â “è ± ââ| ROCm / K8s / Helm / FastAPI /
Prometheusi¼Eç«-ç«â®Ææ^❖ **k8s-llm-runtime**i¼^K8s ä, Šçš,, vLLM
æ`jâž`æœ❖âŠç½ ‘â...³i¼%i¼E**v0.1.0 taggedi¼Eâ❖`çŽ°æ°è • ‘demo**â€, ç + Ýæ,%
Snakemake ç±» Argo Workflows çš,, ML â¹³â❖æŠ½è±jâ€, --- ## æ±,è❖ÆæŠèf½i¼^æE%â²
—â½â❖E¹é...❖æŽ` â°❖i¼E4 â±,i¼% ### â❖Žç«`æ , âçf - Python 3.11+i¼^asyncio, type
hints, Pydantic, httpx asynci¼% - FastAPIi¼^OpenAPI / dependency injection / lifespan¼% -
æµè` • i¼špytest, pytest-asyncio, 88% coverage ### â®¹â™`ä, Žç¼-æŽ` - Dockeri¼^multi-
stage æž,,â°i¼EAlpine é • œâf❖ä¼~â❖-i¼% - Kubernetesi¼^Pod / Service / Deployment /
StatefulSet / ConfigMap / RBACi¼% - Helm charti¼^values æ`jæ❖;â❖-i¼Ehelm install/
upgrade/uninstalli¼EClint cleani¼% - é • œâf❖ä» “â° “i¼šregistry.k8s.io / docker.io /
ghcr.io / nvcr.ioi¼^â½â + ... DaoCloud é • œâf❖âŠ éçYi¼% ### GPU / LLM ç” Ýæ❖ -
vLLMi¼^OpenAI â...¼â®¹ APIi¼EæŽ`ç❖ + æœ❖âŠç; i¼% - AMD ROCm âY°ç;€i¼^HSA / HIP
æ|,âçµi¼Eamd.com/gpu èµ,,æ°❖è`fâ|i¼% - PyTorch¼^CNN æ— ¶ ç©°è Š £ç ❖â™` /
Transformeri¼% - Hugging Facei¼^transformers â° “i¼Etokenizeri¼% ###
â❖`è Š ,æµæ€ Š ä, Žâ • ¥â... é “¾ - Prometheusi¼^prometheus_clienti¼Ehistogram /
counter / gaugei¼% - structlogi¼^JSON structured loggingi¼% - uv / ruff / mypy strict / GitHub
Actions - Linux æœ❖âŠçç«`èç❖ç`i¼^systemd, Nginx, ç«`â❖E/èç`ç®ç❖ + i¼% --- ##
éj¹ç®ç»❖éâE ### k8s-llm-runtimei¼šK8s ä, Šçš,, vLLM æ`jâž`æœ❖âŠç½ ‘â...³i¼^v0.1.0
taggedi¼% **é—éç~**i¼^â-¹â°” JD è❖Eè`£ 1 + 3i¼%i¼švLLM æ`jâž`éf`ç½²éœ€ GPU +
â®¹â™` + è • `ç” ±i¼Eâçé`Yâšä°â...±â°æ— ¶ æ`jâž`ç®ç❖ + â❖æ❖, i¼ç” ç© ¶ /
â°âçé`Yæf³ç” “ OpenAI â...¼â®¹ API æ— ¶ é—æ Š é«~â€, i¼^ç`æŽ`¥â-¹â°”
JD i¼š"âš Š æ`jâž`èç»ç»f/æŽ`ç❖ + Workshopæ❖æ • ™ç`â❖âŠYèf½æ¼” ç«°”i¼%
**æž ¶ æž,, **i¼^â❖E chart + ä, %â±, lib + é • œâf❖ä¼~â❖-i¼%i¼š - `charts/llm-inference/
`i¼švLLM è`Yè½½ charti¼E**GPU vendor â` ± æ❖çä»...é❖ `values.yaml` **i¼^amd.com/
gpu / nvidia.com/gpu / none ä, %æœ❖i¼Evalues æ~¾¼¼❖éç%æ©i¼% - `charts/llm-router/
`i¼šFastAPI ç½ ‘â...³ chart - ConfigMap æ³`â...¥ initContainer âŠ è½½â...â¼Y chart - RBAC
æœ€â®¹æ❖fé™i¼^Pod/Service/ConfigMap read+write + Leasei¼% - ServiceMonitor â❖`éç
%â❖`ç” “i¼^Service 0.0.0.0:9090/metricsi¼% - `src/k8s_llm_runtime/`i¼š3 â±, lib æŠ½è±
j - `K8sJobOperator`i¼^â½Žâ±,i¼Eéçšç” “ Job è`fâ|i¼% - `VLLMInferenceOperator`i¼^â ,
â±,i¼Ehelm CLI subprocess + GPU vendori¼% - `ModelOperator`i¼^éç`â±,i¼EOpenAI â...
¼â®¹ + è ± ââŠ`éf`ç½²i¼% **4 âš Š æŠèæœ`ä°ç, 1**i¼š 1. **lib ä, %â±, â^ + â±, æŠ½è±
j**i¼^â-¹â°” JD â❖Žç«`æž ¶ æž,,èf½âŠi¼% - ä, Šâ±, ModelOperator â❖â...³âçf
load_model(alias) / unload_model(alias) - ä, â±, VLLMInferenceOperator â❖è£... helm
ç» + èŠ, - â½Žâ±, K8sJobOperator éçšç” “ K8s Job è`fâ| 2. \*\*Helm ConfigMap æ³`â...¥
aliases**i¼^â-¹â°” JD â®¹â™`â❖- + èµ,,æ°❖è`fâ|i¼% - é❖;â...❖æ`æ-æjæ-âçžæ`jâž`éf½
rebuild é • œâf❖i¼^GPU é • œâf❖ 15-20GB rebuild 5-10mini¼% - ConfigMap
ç Š` ç° Š ç” Ýæ • ^i¼Eé ¶ é • œâf❖é ± ❖â° 3. **K8s Lease â^ + â, fâ¼❖é” ❖**i¼^â-¹â°”
JD é + ç¾æèç❖ç»` + HAi¼% - coordination.k8s.io/v1 Lease é~²æç Router
âššâ% æœ-â¹ ¶ â❖ ‘éf`ç½²â❖Eä, €æ`jâž`- é” ❖ç²` â°|æE% model
aliasi¼Eè ± ââŠ`èç ± æœY + ç»ç°| 4. **ä, šâŠç° Š Prometheus metrics**i¼^â-¹â°” JD
â¹³â❖â❖`è Š ,æµæ€ Š i¼% - `chat_completions_duration_seconds`i¼^histogrami¼Eâ❖«
status code æ ± ç¾i¼% - `http\_requests\_total`i¼^counteri¼EæE% method/route/statusi¼%

- `models\_loaded` i¼ gauge i¼ Eä ~ in-memory state i¼ % - ServiceMonitor ä - é % è ; >
Grafana **GPU vendor ä + æ demo ** i¼ ^ ä - 1 ä ” JD ä Š ä + GPU é + ç ¾ m i¼ % o i¼ 4 Š -
values.yaml `gpu.vendor=amd|nvidia|none` - AMD i¼ š amd.com/gpu è µ , æ ° è ° f ä o i¼ E ROCm
vLLM é • œ ä f - NVIDIA i¼ š nvidia.com/gpu è µ , æ ° è ° f ä o i¼ E CUDA vLLM é • œ ä f -
none i¼ 4 Š CPU only æ : j ä i¼ i¼ ^ kind cluster é » è ° m i¼ E æ œ - ä œ ä ¼ ä “ ç ” i¼ % ** è
’ ” é + ä ; è - ** i¼ 4 Š - 31 commits / 90 tests pass / coverage 88% - ruff + mypy strict + helm-lint
ä ... ” clean - 2 Helm charts i¼ ^ llm-inference + llm-router i¼ % ** è , @ ä “ ä , Ž ä ; ä m ** i¼ 4 Š -
Service DNS ä , ä ä E é ... ä bug i¼ 4 Š --set fullnameOverride={release_name} ` ä ; ä m - kind
è Š , ç , 1 ä ½ ä + ... é • œ ä f ä Š é Y i¼ 4 Š containerd ConfigPatches + DaoCloud mirror -
è i¼ 4 Š ä ° é f ½ ä + T ä ... ¥ ` docs/amd-interview-demo.md ` ä ¾ , ç Ž ° ä œ ä , è é f
** æ œ ä æ ¥ ** i¼ 4 Š v1.1 i¼ 4 % o i¼ 4 Š SSE æ µ ä ¼ ä æ Ž “ ç + / RBAC æ ” ¶ ç ‘ S ä è - » / ç œ Y ä Ž GPU
é + ç ¾ m e2e ### ä Y ° ä Ž Snakemake ç š , ML
ä 13 ä ° ä • ¥ ä ½ œ æ µ ä ; + æ Ž ¶ i¼ ^ ç ” Y ä ; è f E æ i¼ E ç ± » Argo Workflows i¼ % -
è f E æ i¼ 4 Š Snakemake rule è - æ ³ • æ — æ ³ • ä ° Ž ç Ž æ : j ä — é š æ , ç » , ä ^ -
è ° ¾ è i¼ 4 Š æ “ ä ¼ f rule è - æ ³ • i¼ E ç ‘ æ Ž ¥ è f ä + ... é f æ Ž ¥ ä E ä Š æ æ ç ” Y æ ^
rule i¼ E è S , è E f è ¾ “ ä ... ¥ è ¾ “ ä + ° ç ± » ä Ž ä æ ³ ä - ç S æ œ : ä ¼ ä æ ¼ ä æ Ž ¥ - ä ... ³ è ” i¼ 4 Š JD
ä Š ä + é j 1 æ œ ä T ä ä 1 ä 13 ä ° ç ” ä “ ç » è ä E “ ä ” ä ” æ œ - é j 1 ç , æ - ML ä 13 ä ° æ Š ½ è ±
j ç š , ä • ¥ ç “ ä ° Ž è • µ ### è , “ æ œ æ Ž ¥ ä E CNN è S E ç ä T i¼ ^ PyTorch i¼ % ä è ” ä ” 6 ä “ ä -
j ä 1 è • - ç ° ä S ä + ° - ç « ä ° ç « æ - ¶ ç ° ä • ç S è S E ç EEG ä ; j ä • - PyQt ä Ž æ — ¶ GUI +
FastAPI æ š ‘ é œ ² - è - j è S BCI ä , “ ç ” ç ° ä Ž + ` tracks/brain-computer-interface/notes/
resume.md ` --- ## ä • ¥ ä ½ œ ç » ä Ž + ### ä , Š æ µ • ä °
m é + E ä j ä ; æ - ç S “ æ Š æ œ % é T ä ... - ä , i¼ œ ç ” Y ç % @ ä ; æ - ä • ¥ ç “ ä , ^ i¼ œ
2025.04 - è + ¾ ä Š - ** Docker é f ç ½ ² ** i¼ 4 Š ä , š ä Š j ä E ç Docker ä E - i¼ ^ ä Y ° ä Ž snakemake +
è + a ç ” æ j + æ Ž ¶ i¼ % - ** æ œ ä Š j ç « - è ; ç » ** i¼ 4 Š Linux æ œ ä Š j ä T æ —
¥ ä , ç ‘ æ Š m i¼ E Nginx ä ä ä “ ä E ç + i¼ E systemd æ œ ä Š j ç ; ç + -
** ä ° ä 13 ä ° ä • ¥ ä ... • ä ¼ ä ä “ ** i¼ 4 Š ä , š ä Š j è + ä Š ä E - æ µ ç “ + ç — æ ³ • ä • ¥ ä ... • ###
ä , Š æ µ • æ - S æ “ ç ” Y ç % @ ä E » ä j ç S “ æ Š æ œ % é T ä ... - ä , i¼ œ
ç ” Y ç % @ ä ; æ - ç ” ä “ ä • ¥ ç “ ä , ^ i¼ œ 2022.08 - 2024.07 - ** ä ° ä 13 ä ° ç ” Y ä ; j ä • ¥ ä ...
• ä ¼ ä ä “ ** i¼ 4 Š R / Python / Linux / Docker / ä ° ä Ž Y ç ” Y - ** ä , š ä Š j è + ä Š ä E - ** i¼ 4 Š ä E » ä -
j è ½ - ä ½ • ç » , ä , š ä Š j æ µ ç “ è + ä Š ä E - i¼ E æ : j ä — ä E - ä è ä ä - ä m ç ” -
** ä 13 ä ° ä œ ä ä ° ** i¼ 4 Š [cloud.oebiotech.com] (https://cloud.oebiotech.com/#/home) ###
ä , Š æ µ • æ - S æ “ ç ” Y ç % @ ä E » ä j æ œ % é T ä ... - ä , i¼ œ ç ” Y ç % @ ä ; æ - ä Ž ä 1 ç ” Y i¼ œ
2021.10 - 2022.01 - ä • ç » + è f Ž è ½ - ä ½ • ç » , i¼ 4 Š è
’ æ Ž S ä è ä , è S , ä + æ Ž ä è ä ” ä Ž ä è ä , ä æ S ä E - ä + æ Ž -
ä , » è j æ Š æ œ i¼ 4 Š ä • ç » + è f Ž è ½ - ä ½ • ç » , ä è R ä Python ä Linux --- ##
æ • T è , è f E æ T - ** è ¥ ; ä E — ä + œ æ Ž — ç S “ æ Š ä m S ä j 1 i¼ œ æ m ç % @ ç S “ ä -
j ä , Ž æ Š æ œ - ä , “ ä , š i¼ œ æ œ - ç S “ i¼ œ 2018.09 - 2022.07 i¼ œ GPA i¼ 4 Š 3.35 - æ - ä , š è ° æ -
+ i¼ 4 Š ä Š ä Y ° ä Ž é » è ¾ “ æ - è ” , ä Ž ä ½ ç ; ä ° š ä ° é o j ä è ” ä ¼ ç , ä ... ³ æ S ç Š ¶ ä Š æ Š —
ä è ” æ S ç Š ¶ æ E + æ + ä è - ä m S ä ^ é j 1 ç ° i¼ 4 Š æ 1 ç m è E æ æ Ž ç S ä 1 ç “ è Š ± è œ è “ ä Š —
é “ œ æ ± j æ Y “ š , ä ½ ± ä “ i¼ ^ ä , ä , Ž ä ½ œ è ... i¼ % --- ## ä , ä ° ä ¼ ä Š ä ; - ** 6 ä “ è + ä j K8s
ä Ž ç « - æ ** i¼ 4 Š ä Ž é ¶ ä ^ v0.1.0 tagged é j 1 ç ° i¼ E ç « ä E æ ^ ä E Helm chart + Python
lib - ** ç Ž ä ° demo è f ½ ä Š ** i¼ 4 Š ä è + ä , j ç ” µ è , “ ä œ ” kind cluster ä , Š è • ‘ é Š ä E æ • ‘
LLM æ Ž “ ç + æ µ ç “ i¼ ^ é f ç ½ ² ä + ’ è - ç ” ± ä + ’ chat completions ä + ’ metrics i¼ % -
** ä j ä è f ½ ä Š ä ¼ ** i¼ 4 Š ä 1 ä + ... ä Ž ç ” Y ç % @ ä ; æ - è • “ ç • E ä ^ K8s
ä Ž ç « i¼ E æ Š æ œ - ç f æ f ... é « - ** 3 ä 1 Python ä • ¥ ç “ ä E -
ç » è ä E ** i¼ 4 Š ä Ž ç S “ ç ” è , š æ œ - ä ^ ä ° ä 13 ä ° ä • ¥ ä ... • ç š , ä E æ • è • - ä ¾ ,