

胡盛

- 电话：188-5665-3017
- 邮箱：hs3434@foxmail.com
- 个人网站：hs3434.github.io
- 求职意向：AMD ROCm Python 后端开发工程师（ROCm Radeon Cloud 方向）

个人简介

3 年生物信息工程化经验，自学转型 K8s 后端栈。 容器化部署、资源调度、任务编排、GPU 推理服务。最近 1 周自学 K8s / Helm，独立完成 **k8s-llm-runtime**（K8s 上的 vLLM 模型服务网关），**v0.1.0 tagged**，可现场跑 **demo**。熟悉 Snakemake 类 Workflows 的 ML 平台抽象。

技术博客

- [Transformer 从入门到上手](#)
- [GPT 风格 Transformer 解码 EEG：为什么、怎么做、踩了什么坑](#)
- [从零搭一套端到端 EEG 信号处理工具链](#)

求职技能（按岗位匹配排序）

类别	技能
后端核心	Python 3.11+、FastAPI、pytest
容器与编排	Docker、Kubernetes、Helm、镜像仓库管理
GPU / LLM 生态	vLLM、PyTorch、Hugging Face
工具链	uv、mypy、GitHub Actions
运维	Linux 运维
数据库	PostgreSQL、MySQL、Redis

项目经验

k8s-llm-runtime：K8s 上的 vLLM 模型服务网关 - 自学demo项目

问题（对应 JD 职责 1 + 3）：vLLM 模型部署需 GPU + 容器 + 路由，团队多人共享时模型管理复杂；研究/小团队想用 OpenAI 兼容 API 时门槛高。（直接对应 JD：“大模型训练/推理 Workshop、教程、功能演示”）

架构（双 chart + 三层 lib + 镜像优化）

- charts/llm-inference/: vLLM 负载 chart，**GPU vendor 切换仅靠 values.yaml**（amd.com/gpu / nvidia.com/gpu / none 三态，values 显式选择）
- charts/llm-router/: FastAPI 网关 chart
 - RBAC 最小权限（Pod/Service/ConfigMap read+write + Lease）

- src/k8s_llm_runtime/: 3 层 lib 抽象
 - K8sJobOperator (低层, 通用 Job 调度)
 - VLLMInferenceOperator (中层, helm CLI subprocess + GPU vendor)
 - ModelOperator (高层, OpenAI 兼容 + 自动部署)

4 大技术亮点

1. **lib 三层分层抽象** (对应 JD 后端架构能力)
 - 上层 ModelOperator 只关心 load_model(alias) / unload_model(alias)
 - 中层 VLLMInferenceOperator 封装 helm 细节
 - 低层 K8sJobOperator 通用 K8s Job 调度
2. **Helm ConfigMap 注入 aliases** (对应 JD 容器化 + 资源调度)
 - 避免每次新增模型都 rebuild 镜像 (GPU 镜像 15-20GB rebuild 5-10min)
 - ConfigMap 秒级生效, 零镜像重建
3. **K8s Lease 分布式锁** (对应 JD 集群运维 + HA)
 - coordination.k8s.io/v1 Lease 防止 Router 多副本并发部署同一模型
 - 锁粒度按 model alias, 自动过期 + 续约
4. **业务级 Prometheus metrics** (对应 JD 平台可观测性)
 - chat_completions_duration_seconds (histogram, 含 status code 标签)
 - http_requests_total (counter, 按 method/route/status)
 - models_loaded (gauge, 反映 in-memory state)

GPU vendor 切换 demo (对应 JD 加分 GPU 集群)

- values.yaml gpu.vendor=amd|nvidia|none
- AMD: amd.com/gpu 资源调度, ROCm vLLM 镜像
- NVIDIA: nvidia.com/gpu 资源调度, CUDA vLLM 镜像
- none: CPU only 模式 (kind cluster 默认, 本地开发用)

质量保证

- 31 commits / 90 tests pass / coverage 88%
- ruff + mypy strict + helm-lint 全 clean
- 2 Helm charts (llm-inference + llm-router)

踩坑与修复

- kind 节点国内镜像加速: containerdConfigPatches + DaoCloud mirror

基于 Snakemake 的 ML 平台 workflow 框架 (生信背景)

- 背景: Snakemake rule 语法无法实现模块随意组合
- 设计: 摒弃 rule 语法, 直接调内部接口动态生成 rule, 规范输入输出类型即可积木式拼接
- 关联: JD 加分项 “机器学习平台研发经验” —— 本项目是 ML 平台抽象的工程实践
- **详细博客**: [不满 Snakemake 的静态 rule? 我用 Python 对象动态构建了一条 RNA-seq 流水线](#)

脑机接口 CNN 解码器 (PyTorch) —— 自学的demo项目

- 端到端时空卷积解码 EEG 信号
- PyQt 实时 GUI + FastAPI 暴露

- 仓库: github.com/hs3434/bci-pipeline-demo
-

工作经历

上海尤里卡信息科技有限公司 | 生物信息工程师 | 2025.04 - 至今

- **rnaseq** (项目主力): 基于 Snakemake 的 RNA-seq 自动化分析 pipeline, Docker / Apptainer 容器化, 20 核并行; config.yaml 驱动配置; 公司业务自动化主线
- **helix** (Python 后端 API): FastAPI + Click + Pydantic v2 实现的生物信息 API 服务, 给 rnaseq pipeline 提供结果展示层; 类型化 + 测试覆盖
- **服务端运维**: Linux 服务器日常维护, Nginx 反向代理, systemd 服务管理

上海欧易生物医学科技有限公司 | 生物信息研发工程师 | 2022.08 - 2024.07

- **云平台生信工具开发**: R / Python / Linux / Docker / 云原生
- **业务自动化**: 医学转录组业务流程自动化, 模块化、可复用
- **平台地址**: cloud.oebiotech.com

上海欧易生物医学有限公司 | 生物信息实习生 | 2021.10 - 2022.01

- 单细胞转录组: 质控、常规分析、售后、个性化分析
 - 主要技术: 单细胞转录组、R、Python、Linux
-

教育背景

西北农林科技大学 | 植物科学与技术专业 | 本科 | 2018.09 - 2022.07 | GPA: 3.35

- 毕业论文: 《基于逻辑斯蒂回归确定小麦倒伏相关性状及抗倒性状指标》
 - 大创项目: 根瘤菌接种对紫花苜蓿抗铜污染的影响 (参与作者)
-

个人优势

- **1 周自学 K8s 后端栈**: 从零到 v0.1.0 tagged 项目, 独立完成双 Helm chart + Python lib
- **现场 demo 能力**: 可自带电脑在 kind cluster 上跑通完整 LLM 推理流程 (部署 → 路由 → chat completions → metrics)
- **学习能力强**: 自学生物信息、算法、K8s 等多领域知识, 独立完成项目
- **3 年 Python 工程化经验**: 从科研脚本到云平台工具的完整路径